Quem de Fato Colabora nos Repositórios Web3? Evidência Preliminar sobre Core e Occasional Contributors

Pamella Soares
Universidade Estadual do Ceará (UECE)
Fortaleza, Brasil
pamella.soares@aluno.uece.br

***Resumo*—Narrativas sobre open source Web3 frequentemente pressupõem colaboração ampla. Neste *work-in-progress*, provocamos essa premissa: quem de fato concentra a colaboração observável em repositórios *provider*? Usando o Web3BlockSet [1] (somente providers; 2018–2025), rotulamos *core* como o top 10% de autores por Issues/PRs abertos em cada repositório e contrastamos com *occasional contributors*. Em 316 repositórios (≈360k documentos; 59k autores), o core abre 69% dos documentos; aparece em 59% das threads iniciadas por occasionals; e o Gini mediano de autoria é 0,55. Ano a ano, a concentração na abertura permanece alta, enquanto a taxa de aparição do core em threads da periferia *cai* (0,69→0,36). Escopo deliberadamente limitado—sem topic modeling nem SPACE/BcDEx [2].**

***Index Terms*—Mining Software Repositories, Web3, colaboração, core developers, work-in-progress**

I. Introdução e Provocação

Em ecossistemas Web3, é comum falar em "comunidade de desenvolvedores". Porém, a atividade observável em OSS costuma ser desigual entre núcleo e periferia [3], [4]. A provocação deste short é:

> *Se ≈10% dos autores abrem a maior parte dos Issues/PRs—e ainda assim o núcleo participa de boa parte das threads da periferia—então métricas e políticas que tratam a comunidade como massa homogênea podem estar otimizando um mito.*

Esta nota não fecha o debate sobre saúde de comunidades Web3. Nos termos do MSR para *work-in-progress*, seu papel é apresentar uma ideia controversa/interessante com evidência preliminar suficiente para discussão—não a avaliação completa de um full paper.

RQ: Como se diferenciam *core* e *occasional contributors* na colaboração observável (abertura e participação em threads) dos repositórios provider do Web3BlockSet (2018–2025)?

a) Por que isto é WIP.: Não estimamos causalidade de retenção, não fechamos validação de afiliação organizacional em escala e **não** reanalizamos "dores"/DEx em BaaS [2]. A contribuição é reposicionar o olhar: de *o que* se discute para *quem* sustenta a colaboração observável.

II. Trabalho Relacionado (posicionamento)

A distinção core/periferia é clássica em engenharia de software aberta. Joblin et al. [4] mostram que métricas de contagem e de rede classificam desenvolvedores em núcleo e periferia com implicações para coordenação. Em blockchain, Das et al. [3] caracterizam colaboração em repositórios GitHub, enquanto tipologias de issues [5] e a agenda BOSE [6] enfatizam especificidades do domínio. O Web3BlockSet [1] habilita análises em escala com categorias de stack validadas. Já estudos de BcDEx em BaaS [2] aprofundam *o que* se discute e dimensões de produtividade/experiência.

Este WIP ocupa um espaço ortogonal: não pergunta quais tópicos doem, e sim **quão concentrada** é a colaboração observável e como core e occasionals se relacionam em threads. Usamos métricas simples e replicáveis (top 10%, Gini/HHI, participação do core em threads da periferia), explicitamente evitando overlap com topic modeling e SPACE.

III. Dados e Método (limitado)

A. Corpus

Issues/PRs com `data_source=provider` e `repository_category` validada no Web3BlockSet [1], anos 2018–2025. Após filtros (≥30 documentos/repo), permanecem 316 repositórios, ≈360 183 documentos e 59 141 autores. Campos centrais: `author`, `comment_authors` (separados por ';'), repositório e categoria.

B. Definição operacional de papéis

Em cada repositório, ordenamos autores pelo número de Issues/PRs *abertos* e definimos:

- **core:** top 10% dos autores (pelo menos um);
- **occasional:** demais autores.

Essa definição torna o share de documentos um *resultado* (não uma tautologia do tipo "core = quem faz 80%"). A categoria do stack entra apenas como estratificação secundária.

C. Métricas

(1) Gini e HHI da distribuição de autoria por repositório; (2) share global/anual de documentos abertos pelo core; (3) taxa em que algum autor core aparece em `comment_authors` quando o opener é occasional; (4) número médio de comentadores únicos por thread; (5) Gini mediano por categoria validada.

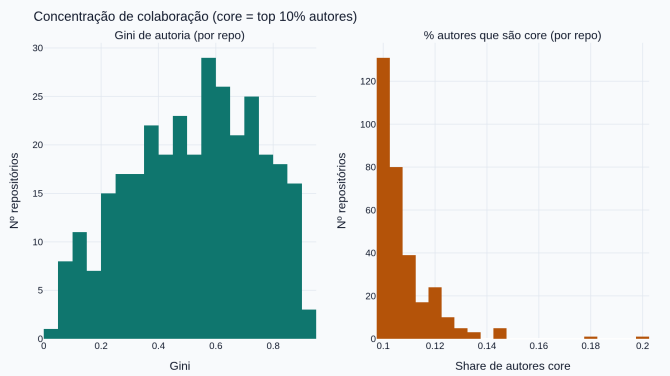


Figura 1. Distribuição, entre repositórios, do Gini de autoria e da fração de autores no core (top 10%).

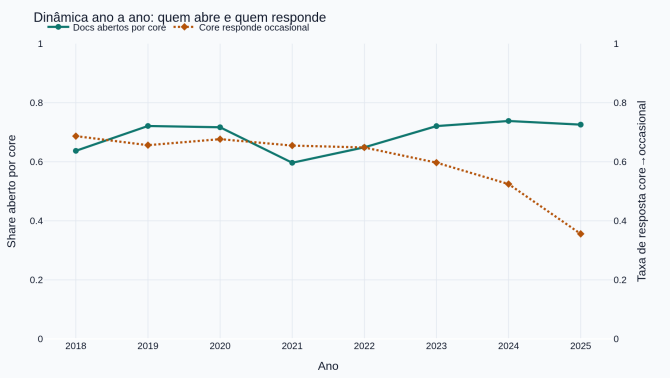


Figura 2. Ano a ano: share de documentos abertos pelo core e taxa de aparição do core em threads iniciadas por occasionals.

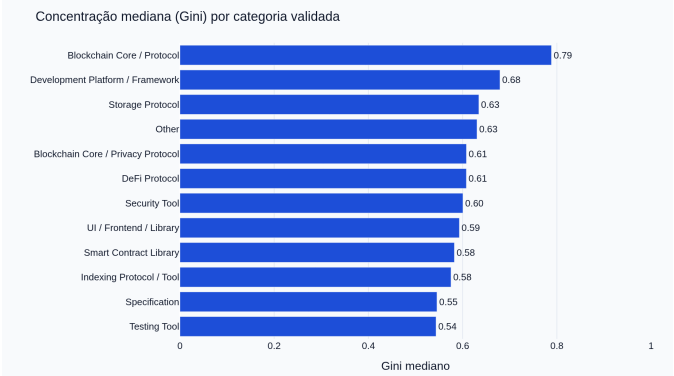


Figura 3. Gini mediano por categoria validada (repositórios com atividade suficiente).

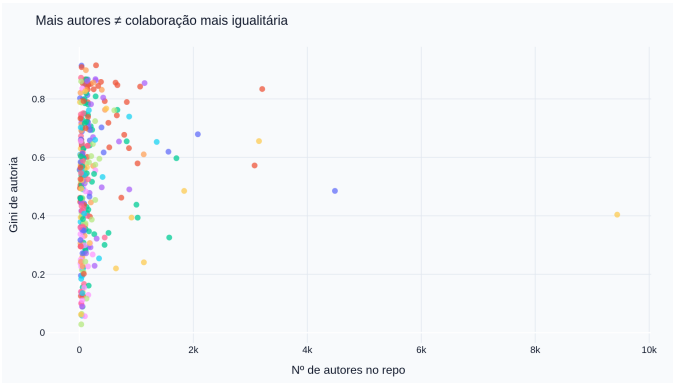


Figura 4. Número de autores versus Gini: ter muitos participantes não implica colaboração igualitária.

D. Validação manual

Amostra cega estratificada por categoria×papel automático (`data/manual_review/`; n=445) pede a revisores inferir o papel real (`core_maintainer`, `regular`, `occasional`, `bot_or_automation`, `unsure`) e afiliação aparente à organização, sem ver o rótulo automático. Protocolo em `PROTOCOL_MANUAL_REVIEW.md`. Neste WIP descrevemos o desenho; κ e precisão entram após dupla anotação.

IV. Evidência Preliminar

a) Achado 1—Concentração na abertura.: O top 10% de autores abre **69,1%** dos documentos no corpus filtrado. O Gini mediano por repositório é **0,55**; a mediana é de ≈8–9 autores core em ≈80 autores/repo (Figura 1). Isso sustenta a provocação de assimetria: a "comunidade" listável é maior do que o conjunto que de fato impulsiona a maior parte da atividade observável.

b) Achado 2—O core ainda atravessa a periferia.: Em **59,0%** das threads abertas por occasionals, algum autor core aparece em `comment_authors`. Ou seja, mesmo quando a periferia inicia a conversa, o núcleo frequentemente permanece na thread—padrão compatível com suporte, revisão ou triagem centralizada.

c) Achado 3—Dinâmica temporal (miolo anual).: Entre 2018 e 2025 (Figura 2 e Tabela I), a share de documentos abertos pelo core permanece alta (≈0,64–0,74). Em contraste, a taxa de aparição do core em threads da periferia **declina** de 0,69 (2018) para 0,36 (2025). O número médio de comentadores únicos por thread também cai (1,63→0,64). Essa combinação é thought-provoking: não vemos "democratização" da abertura; vemos possível *afastamento relativo* do núcleo nas conversas da periferia (hipótese a testar—pode refletir escala, automação, ou mudança de canais para Discord/fora do GitHub).

d) Achado 4—Heterogeneidade por categoria.: O Gini mediano varia entre camadas do stack (Figura 3). Portanto, generalizações "Web3-wide" sobre colaboração podem falhar se ignorarem o tipo de repositório. A Figura 4 reforça que *mais autores* não implicam automaticamente menor desigualdade.

e) Achado 5—Escala não equaliza.: Repositórios com dezenas ou centenas de autores ainda podem exibir Gini elevado. Em outras palavras, "muitos nomes" no histórico de Issues/PRs é evidência fraca de colaboração distribuída. Para o WIP, isso importa porque dashboards baseados apenas em contribuidores únicos tendem a superestimar amplitude comunitária.

Tabela I
MÉTRICAS ANUAIS DE COLABORAÇÃO (PROVIDERS).

Ano	Docs	Core abre	Core em occ.	Gini med.
2018	24 699	0,64	0,69	0,46
2019	27 619	0,72	0,66	0,47
2020	33 918	0,72	0,68	0,49
2021	48 057	0,60	0,65	0,43
2022	53 755	0,65	0,65	0,42
2023	57 330	0,72	0,60	0,49
2024	57 482	0,74	0,52	0,49
2025	57 323	0,73	0,36	0,50

A. Síntese da provocação

Combinando os achados: (i) poucos abrem a maior parte; (ii) o núcleo ainda aparece em muitas threads da periferia; (iii) essa ponte enfraquece no tempo; (iv) o grau de concentração depende da camada. A leitura controversa—ainda hipotética—é que parte do discurso de "comunidade Web3" descreve uma periferia larga acoplada a um núcleo pequeno, e que o acoplamento observável no GitHub pode estar diminuindo sem que a desigualdade na abertura desapareça.

V. IMPACTO, ATENÇÕES E REMEDIAÇÕES

A. Impacto no ecossistema Web3

- **Pesquisa:** agregar todos os autores como "comunidade" mistura regimes core/periferia e pode inflar percepções de engajamento.
- **Foundations/plataformas:** bus factor—poucos abrem a maior parte da atividade observável; sucessão e distribuição de carga importam.
- **Onboarding:** volume de nomes em Issues $\neq$ rede densa; newcomers provavelmente interagem com um núcleo pequeno.
- **Governança e suporte:** se a participação do core nas threads da periferia cai ao longo do tempo, há risco de fila não atendida e churn de contribuidores ocasionais—mesmo com alta concentração na abertura.
- **Métricas de saúde OSS:** dashboards que só contam contribuidores únicos podem pintar um quadro otimista demais.

B. Atenções (ameaças ao overclaim)

- Top-10% é proxy de papel, não membership GitHub nem "maintainer" oficial.
- Bots residuais podem inflar ou distorcer caudas.
- `comment_authors` pode estar incompleto; ausência de core na lista $\neq$ ausência real de resposta.
- Queda da taxa de participação pode refletir crescimento do volume, migração para outros canais, ou mudança de práticas—não necessariamente desengajamento deliberado.
- Resultados são para providers; não generalizamos para adopters community.

C. Remediações recomendadas

- Sempre reportar métricas separadas para core vs periferia.
- Monitorar bus factor e tempo/participação em threads abertas por occasionals.
- Validar papéis (amostra manual + afiliação organizacional via API).
- Em estudos futuros, ligar papéis a retenção (ponte natural para a RQ3b do Web3BlockSet) e a redes de co-comentário.

VI. AMEAÇAS À VALIDADE

a) Construto.: Abertura de Issues/PRs captura iniciativa observável, não horas de trabalho nem qualidade. Participação em `comment_authors` é proxy grosseiro de "resposta".

b) Interna.: A escolha do limiar 10% é convencional; sensibilidades (5%/15%) ficam para o full paper. Repositórios pequenos foram excluídos ($<$30 docs), o que pode enviesar para projetos mais ativos.

c) Externa.: Cobertura do Web3BlockSet e foco em providers limitam generalização. Ecossistemas fora de GitHub não são observados.

d) Confiabilidade.: A amostra cega (n=445) ainda precisa de dupla anotação; até lá, a heurística deve ser lida como operacionalização transparente, não como ground truth.

VII. PRÓXIMOS PASSOS

1) fechar dupla anotação cega e reportar precisão/κ da heurística top-10%;
2) segundo critério de core via afiliação organizacional (GitHub org members);
3) redes de co-comentário e centralidade ao longo do tempo;
4) analisar se a queda da participação do core persiste após normalizar por volume;
5) ponte com retenção de contribuidores (RQ3b);
6) full paper com hipóteses pré-registradas e análises de sensibilidade.

VIII. IMPLICAÇÕES PARA O DESENHO DE ESTUDOS FUTUROS

Se os padrões se confirmarem sob validação manual e sensibilidades de limiar, sugerimos três práticas mínimas em estudos MSR sobre Web3: (1) **sempre** separar core e periferia ao reportar atividade; (2) acompanhar não só volume de contribuidores, mas *quem responde a quem*; (3) estratificar por categoria de repositório quando a pergunta for sobre o ecossistema como um todo. Essas práticas são baratas, alinhadas a open science, e reduzem o risco de conclusões infladas sobre "engajamento comunitário".

IX. CONCLUSÃO

Este WIP desloca o foco de "o que dói nos desenvolvedores Web3" para **quem sustenta a colaboração observável**. Evidência preliminar em providers: poucas pessoas abrem a maior parte da atividade; o núcleo ainda atravessa muitas threads da periferia; e essa ponte parece enfraquecer no tempo. A provocação—ainda em formação—é que pesquisas e práticas não deveriam tratar a comunidade Web3 como massa homogênea. O valor do short está em tornar essa tensão discutível com

dados, figuras e um protocolo de validação já preparado—não em encerrar o caso.

Disponibilidade de Dados

Artefatos (scripts, tabelas, figuras, protocolo e amostra cega) estão em `2027_short_paper_3a`. O dataset-base é o Web3BlockSet [1]. Para submissão double-anonymous, o pacote será depositado de forma anonimizada.

Referências

[1] P. Soares, G. Destefanis, A. C. N. dos Santos, A. A. Araújo, R. Saraiva, and J. Souza, "Web3BlockSet: A dataset for empirical research in blockchain-oriented software engineering," in *Proceedings of the 23rd International Conference on Mining Software Repositories*, 2026.

[2] ——, "Characterizing developer experience in blockchain-as-a-service platforms: An empirical study of GitHub issues and pull requests," *Empirical Software Engineering*, 2025, manuscript.

[3] A. Das, G. Uddin, and G. Ruhe, "An empirical study of blockchain repositories in GitHub," in *Proceedings of the 26th International Conference on Evaluation and Assessment in Software Engineering*, 2022, pp. 211–220.

[4] M. Joblin, S. Apel, C. Hunsen, and W. Mauerer, "Classifying developers into core and peripheral: An empirical study on count and network metrics," in *2017 IEEE/ACM 39th International Conference on Software Engineering (ICSE)*. IEEE, 2017, pp. 164–174.

[5] M. N. I. Opu, M. S. Islam, S. Rouhani, and S. Chowdhury, "Understanding the issue types in open source blockchain-based software projects with the transformer-based BERTopic," *arXiv preprint arXiv:2506.11451*, 2025.

[6] S. Porru, A. Pinna, M. Marchesi, and R. Tonelli, "Blockchain-oriented software engineering: challenges and new directions," in *2017 IEEE/ACM 39th International Conference on Software Engineering Companion (ICSE-C)*. IEEE, 2017, pp. 169–171.